

Predicting Loss Curve of LLM Pretraining

Course Project Task 2

王渭臻, 1900010767, 本科生

GitHub repository: https://github.com/Tomori47/task2_loss_prediction

June 19, 2026

Problem Background



- LLM 预训练成本很高，因此希望提前预测训练过程中的 loss curve。
- Scaling laws 研究模型规模、数据规模、训练计算量和 loss 的关系。
- Loss curve prediction 进一步关注整个训练过程，而不只是最终 loss。
- Learning rate schedule 会影响后期 loss 下降速度和最终效果。

Task Objective

- 课程 Task 2 要求：使用 cosine LRS 的 loss curve 拟合模型。
- 主测试：预测 WSD LRS 下的 loss curve。
- 附加测试：在 811 LRS 上评估泛化效果。
- 评价指标：MAE、MSE、RMSE、MAPE。

Data Description

- 数据文件: data/gpt_loss+lr.pkl
- 三条曲线: cosine_rope、wsd_rope、811_rope
- 每条曲线包含: step、Metrics/loss、lr



Experimental Setting

Split	Curve
Fit	M:100M_gpt_D:20B_scheduler:cosine_rope
Main test	M:100M_gpt_D:20B_scheduler:wsd_rope
Additional test	M:100M_gpt_D:20B_scheduler:811_rope

- 所有方法使用相同的 fit/test 划分。
- 目标是检查从 cosine schedule 到 WSD schedule 的预测能力。

Model

$$L(s) = L_0 + A \cdot S_1(s)^{-\alpha} - C \cdot S_2(s)$$

- $S_1(s)$: 累计学习率。
- $S_2(s)$: learning rate annealing 修正项。
- 本项目中固定 $\text{lambda_decay} = 0.99$ 。
- 直觉: loss 随累计训练强度下降, 同时由学习率衰减项修正。

Baseline 2: Simplified Multi-Power Law

Simplified MPL

$$L(t) = L_0 + A \cdot (S_1(t) + \epsilon)^{-\alpha} - B \cdot D(t)$$

$$D(t) = \sum_{k=1}^t \max(lr_{k-1} - lr_k, 0) \cdot (S_{\text{tail}}(k, t) + \epsilon)$$

- 这是简化实现，没有完全复现 Luo et al. 的所有训练细节。
- 保留两个核心思想：累计学习率项和学习率衰减修正项。

Our Method: Weighted Tissue

- 预测公式仍然使用 Tissue 形式。
- 改动只在拟合目标：对后期 step 给予更高权重。

Weighted Least Squares

$$\min \sum_{\mathbf{s}} w_{\mathbf{s}} (L_{\text{true}}(\mathbf{s}) - L_{\text{pred}}(\mathbf{s}))^2$$

$$w_{\mathbf{s}} = 1 + \gamma \cdot \frac{\mathbf{s}}{T}, \quad \gamma = 2.0$$

- 直觉：后期 loss 和最终 loss 更重要，因此拟合时更重视后期曲线。


Results on Cosine Fit

Method	MAE	RMSE	MAPE
Tissue	0.07730	0.15378	2.40%
Simplified MPL	0.07730	0.15378	2.40%
Weighted Tissue	0.07200	0.15463	2.20%

- 三种方法都能拟合 cosine loss 的主要趋势。
- Weighted Tissue 的 MAE 和 MAPE 更低，但 RMSE 略高。


Results on WSD Prediction

- 主测试：在 WSD LRS 上预测 loss curve。
- 下图比较 ground truth、Tissue、simplified MPL 和 Weighted Tissue。



Weighted Tissue on WSD

- MAE = 0.13999
- RMSE = 0.19436
- MAPE = 4.64%
- 相比 baseline 有小幅改善。



Quantitative Comparison

Method	MAE	RMSE	MAPE
Tissue	0.15364	0.20276	5.14%
Simplified MPL	0.15364	0.20275	5.14%
Weighted Tissue	0.13999	0.19436	4.64%

- Weighted Tissue 将 WSD MAE 从约 0.15364 降到 0.13999。
- Weighted Tissue 将 WSD MAPE 从约 5.14% 降到 4.64%。

- Tissue 和 simplified MPL 的衰减修正项在当前数据中几乎收敛到 0。
- 说明只用一条 cosine 曲线拟合时，模型主要依赖累计学习率 power-law 项。
- Weighted Tissue 没有改变模型形式，只改变拟合权重。
- 通过强调后期 loss，Weighted Tissue 在 WSD 预测上获得小幅改善。

Limitations

- 只使用了三条 loss curves, 数据规模较小。
- Simplified MPL 没有完全复现 Luo et al. 的完整模型。
- 没有进行大规模超参数搜索。
- Weighted Tissue 只使用固定的 $\gamma = 2.0$ 。
- 结果主要作为低成本课程复现实验。

Conclusion

- 完成 Tissue baseline。
- 完成 simplified Multi-Power Law baseline。
- 提出并实现 Weighted Tissue fitting。
- 在 WSD 主测试上，Weighted Tissue 相比 baseline 有小幅改善。
- 已生成代码、CSV 指标、图像、README 和 slides。

- GitHub repository: https://github.com/Tomori47/task2_loss_prediction
- Team members: 王渭臻, 1900010767, 本科生
- 关键输出:
 - results/metrics_summary.csv
 - figures/method_comparison_wsd.png
 - slides/task2_loss_prediction_slides.tex

- Tissue et al., 2024. *Scaling Law with Learning Rate Annealing*.
- Luo et al., 2024/2025. *Multi-Power Law Scaling for Loss Curve Prediction*.
- Course Task 2 handout: *Predicting Loss Curve of LLM Pretraining*.